

Mesterséges Intelligencia: hitek és tévhitek

Jakovác Antal

Wigner RCP, Corvinus University Budapest

IX. ONKO-KARDIOLÓGIAI NAPOK, 2026. április 24–25.

A Mesterséges Intelligencia hódításai

A Mesterséges Intelligencia (MI, AI) korát éljük...

- multimodális rendszerek
 - ➔ szöveg, kód, kép, beszéd, videó értés és generálás
 - ➔ ChatGPT, Gemini, Deepseek, Grok, Claude, ...
- specializált rendszerek
 - ➔ játékok, önvezető autók, ajánlórendszerek, fehérje szerkezet, időjárás előrejelzés, diagnosztika ...
- azt kell megindokolni, miért nem használ valaki AI-t...
- sok területen eléri/meghaladja az emberi teljesítményt (nyelvi modellek, játékok, diagnosztika)



Hogyan képes erre? Mik a határok?

Három kérdés mentén vizsgáljuk az MI-t

- Lehet egy gép okosabb, mint az alkotója?
- Miért hazudik/hallucinál az MI?
- Gondolkodik-e az MI?


- ➔ van-e öntudata?
- ➔ minden emberi munkát el fog tudni végezni?
- ➔ átveszi a hatalmat? „ítélelnap” (doomsday)

(Paperclip Maximizer (Bostrom, 2003), AI Arms Race (Hawking, Musk, 2010))




Lehet egy gép okosabb, mint az alkotója?

- **filozófiai kérdés ...**
- **hagyományos problémamegoldás**
 - ➔ probléma megértése
 - ➔ algoritmus kidolgozása
 - ➔ (gépi) megoldás
- **MI problémamegoldás**
 - ➔ megértés/tanulás megértése
 - ➔ problémamegoldó algoritmus kidolgozása
 - ➔ a gép végzi az aktuális probléma megértését és megoldását
 - ➔ nem biztos, hogy tudjuk, mit csinál...



Miért hazudik/hallucinál az MI?

- MI $\equiv$ megértés megértése $\rightarrow$ hogyan értjük ma a megértést?
- **feladat (akció) orientált hozzáállás:** az ágens célja, hogy a környezeti jelenségekre megfelelő cselekvéssel válaszoljon



- a mai MI rendszerek alapvetően így működnek!

Miért hazudik/hallucinál az MI?

- **megvalósítás**


- ➔ adatokat gyűjtünk a bemenet → helyes kimenet összefüggésről működő rendszer (supervised), saját kárunkon (reinforcement)
- ➔ függvényillesztés → eredmény valószínűség (mi van a képen, mi a következő szó)

- **következménye:** intuitív, „megérzés” alapú feladatmegoldás

- ➔ nem tudja, mit nem tud/mit tud/mikor mond rosszat
- ➔ hallucinálás, kreativitás, jó kérdés jelentősége
- ➔ emberi gondolkodás részben így működik → System 1 (Kahneman) *lassan tanulható, gyors, automatikus, intuitív, érzelmi, nem tudatos* ösztönös reakciók, olvasás, arcfelismerés, anyanyelv, ...

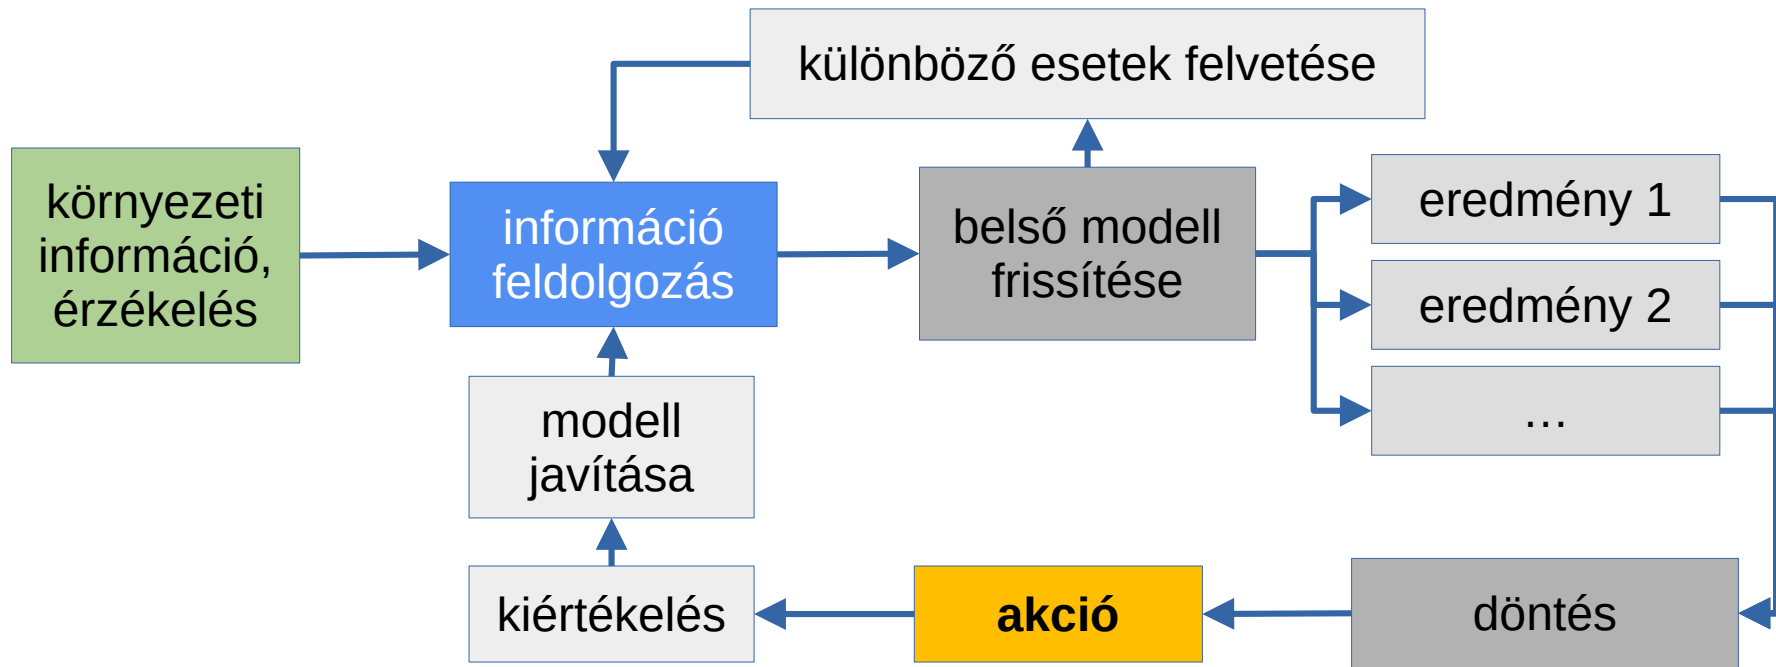
Gondolkodik-e az MI?

- **intuitív válaszadás $\neq$ gondolkodás**
- **környezeti reprezentáció hozzáállás**
 - ➔ bonyolult környezet $\rightarrow$ nem lehet mindenre közvetlen választ adni!
 - ➔ megoldás: belső modell (állapot, világ modell)



Gondolkodik-e az MI?

- **környezeti reprezentáció hozzáállás** → részletesebb kép



Gondolkodik-e az MI?

Környezeti reprezentáció hozzáállás következményei

- **gondolkodás** → modell futtatása, következmények kidolgozása
- **tervezés/akarat/cél** → a világ ilyen volt, és olyan lesz
- **önkép/öntudat** → önmagunk elhelyezése a világban
- emberi gondolkodásban: System 2 (Kahneman)
lassabb, logikus, értelmi, tudatos, általános
térbeli tájékozódás, tervezés, helyzetértékelés, döntés, hazugság, ...

Gondolkodik-e az MI?

- **környezet reprezentálása kezdetleges a mai AI-ban**
 - ➔ nagy nyelvi modellekben: általános tudás több milliárd paraméter, konkrét valóság kb. 100 ezer token
- **javítási törekvések**
 - ➔ visszacsatolás (reasoning), RAG rendszerek
 - ➔ reprezentáció tanulás (representation learning)
feature generation, vektor adatbázisok, nem felügyelt tanítás (VAE)
 - ➔ emberi fogalomalkotás jobb megértése → hierarchia, absztrakció, általánosítás, tudástér kibővítése

Összefoglalás

- **hol tart ma az MI?**

- ➔ multimodális System 1: heurisztikus feladatok megoldása
- ➔ valóság reprezentáció nem elég: nincs System 2 (gondolkodás, tervezés, öntudat) → automatikusan feltételezzük ...

- **mire alkalmas és mire nem az MI**

- ➔ jó mintafelismerés, monotonitás tűrés, nem fárad → előfeldolgozás
- ➔ nyelvi modellek az emberiség tudását hordozzák → lexikon
- ➔ döntés következményeit nem tudja felmérni → emberi kontroll